

유가 데이터 주유소 시장분석 — 프로젝트 안내서 & 모범답안 해부

이 문서는 두 부분입니다. - Part A. 이게 무슨 프로젝트인가요? → 처음 보는 사람도 이해할 수 있는 친절한 설명 - Part B. 모범답안(완성본) 완전 해부 → 실제 완성본이 무엇을 어떻게 했는지 (숫자 포함)

Part A. 이게 무슨 프로젝트인가요? (친절한 설명)

① 한 문장으로

"전국 주유소들의 기름값 표를 받아서, 거기 숨은 재미있는 사실을 찾아내고, 그걸 발표로 설명하는 프로젝트"

🔍 비유: 우리 반 친구들 키·몸무게 표로 "우리 반은 이런 특징이 있어요"를 찾아 발표하듯이, 친구 → 주유소, 키 → 기름값으로 똑같이 하는 거예요. (대상: 전국 모든 주유소 / 기간: 2018~2021년 4년치)

② 무엇을 해야 하나 (큰 흐름 4단계)

요리에 비유하면:

단계	요리로 치면	실제로 하는 일
1	🔪 재료 손질	데이터 정리 (지저분한 표를 깨끗하게)
2	🔍 요리하기	분석 (질문에 답 찾기)
3	🍽️ 예쁘게 담기	차트(그래프) 만들기
4	🍷 손님상에 내기	발표자료 만들기 ← 진짜 목표!

분석에서 답할 질문(유가): ①주유소가 늘었나 줄었나 ②어느 브랜드가 비싼가 ③셀프가 싼가 ④동네마다 다른가 ➕ 중간에 퀴즈 2개도 풀어서 엘리스 제출 (수료 도장용)

③ 무엇을 제출하나 (최종 결과물)

- 📄 분석 노트북(.ipynb) — 코드+결과
- 📊 발표 슬라이드(.pptx) — 사람들 앞에서 보여줄 것 ← 사실상 최종 목표
- ✅ 엘리스 퀴즈 제출

④ ★가장 중요★ 그냥 분석하면 안 되고 "규칙 3개"를 지켜야 함

이 숙제의 진짜 목적은 분석 자체보다 "잘 설명하고 설득하는 법"을 배우는 것. 그래서 규칙이 3개 있어요.

- 규칙 1 SCQA — 이야기를 시작하는 공식: **상황**(요즘 기름값 비싸죠?) → **문제**(근데 주유소마다 달라요) → **질문**(왜 다를까?) → **답**(분석해보니 ○○ 때문!)
- 규칙 2 민토 피라미드 — 결론을 맨 위에 먼저 말하고 그 아래에 이유 3개로 받치기
- 규칙 3 Wilke 시각화 — "예쁘게"가 아니라 "한눈에 이해되게" 그래프 그리기 (제목만 봐도 알게, 색은 의미 있게, 크기 순 정렬)

👉 이 규칙 3개가 완성본에서 실제 숫자와 함께 어떻게 쓰였는지는 아래 Part B에서 확인하세요.

⑤ 무엇을 알아야 하나

- 도구: 파이썬, pandas(표 다루기), matplotlib·seaborn(그래프), folium(지도)
 - 통계 개념: 평균·중앙값, 표준편차, ANOVA, t-검정, 변동계수 등 → 맨 아래 [통계 용어 한 줄 정리] 표 참고. 지금 외울 필요 전혀 없어요.
-

Part B. 모범답안(완성본) 완전 해부

대상 파일: 02_데이터분석프로젝트/01_유가_데이터_주유소_시장분석/주유소_가격_시장분석_SCQA_실행.ipynb + 발표 자료 예시: 주유소_시장분석_보고서(예시).pptx (10장) 모든 숫자는 노트북에서 실제로 계산된 값 기준.

0. 어떤 데이터를 썼나

항목	내용
원본	320,539행 (주유소 × 날짜별 기름값 기록)
청소 후	가격 0원(영업중단) 1,320개 제거 → 319,219행
분석 단위	"한 주유소의 한 해 평균"으로 묶음 → 45,809건
규모	주유소 약 11,000개 · 17개 시도 · 10개 브랜드 · 4개년(2018~2021)
기간	매년 6월 1~7일(1주일치) · 출처: 한국석유공사 Opinet
컬럼	번호(주유소ID) · 기간 · 지역 · 상표(브랜드) · 셀프여부 · 휘발유(가격)
브랜드	GS칼텍스, NC오일, NH-OIL, S-OIL, SK가스, SK에너지, 알뜰(ex), 알뜰주유소, 자가상표, 현대오일뱅크

💡 핵심 아이디어: 매일 데이터는 너무 많으니 "주유소별 1년 평균값"으로 요약해서 다룸. (반 친구 매일 키 재는 대신 "1년 평균 키"로 보는 것과 같음)

1. 이 발표의 "한 줄 결론" (피라미드 꼭대기)

"한국 기름값은 2020년 코로나로 확 떨어졌다가 반등했고, 브랜드·셀프여부·지역에 따른 가격 차이는 계속 유지된다."

이 한 문장을 근거 4개로 받친다. ↓

2. 파트별 해부 (각 파트 = 질문 1개 + 방법 + 실제 결과)

📌 Part 1. 연도별 가격 — "4년간 어떻게 변했나?"

- 방법: 평균·중앙값·표준편차·IQR·왜도(기초통계) + 선그래프(평균 $\pm$ 1표준편차 밴드)
- 실제 결과:

연도	평균가격	표준편차	비고
2018	1,609원	57.0	
2019	1,535원	55.8	
2020	1,284원	65.2	🦠 코로나로 역대 최저
2021	1,559원	51.8	다시 반등

- 발견: 기름값 쌀 때(2020)는 주유소 간 격차도 줄어듦. 왜도(+)라서 "비싼 주유소 몇 개"가 평균을 끌어올림 → **중앙값**이 더 현실적.

📌 Part 2. 브랜드 — "어디가 비싸고 잘나가나?"

- 방법: ANOVA(3개 이상 그룹 차이 검정) + η^2 (효과크기) + Boxplot + Stacked Bar/Heatmap(점유율)
- 실제 결과: $F=80.5$, $p=1.46e-114$ (<0.001) → "브랜드별 가격차이는 우연 아님" ✅
- $\eta^2=0.048$ → 브랜드가 가격차이의 약 4.8% 설명 (작은 효과)
- 알뜰계열이 제일 싼, 자가상표가 제일 비싸고 분산 큼
- 점유율 변화: SK에너지 31.7%→27.2%(📉 하락) / 현대오일뱅크·알뜰계열 소폭 상승

📌 Part 3. 셀프 vs 일반 — "셀프가 진짜 싼가?"

- 방법: 독립표본 t-검정(Welch) + Cohen's d(효과크기) + Paired dot plot
- 실제 결과: 셀프가 매년 더 싼 4년 평균 약 -28원/L

연도	셀프평균	일반평균	차이	Cohen's d
2018	1,595	1,619	-23원	-0.43
2019	1,519	1,546	-27원	-0.51
2020	1,264	1,297	-34원	-0.56
2021	1,541	1,571	-29원	-0.62

- 소비자 의미: 1년 720L 기준 연 약 2만원 절약. 2020년 저유가 때 격차가 가장 큼(일반이 더 천천히 내림).

📍 Part 4. 지역 — "어디 살면 제일 비싸게 냅나?"

- 방법: 지역별 기초통계 + 분산분해(지역간/지역내) + 수평 Boxplot/히트맵 + Folium 지도
- 실제 결과(2021):

순위	지역	평균	특징
1	서울	1,641원	제일 비쌌 + 편차도 최대(std 152)
2	제주	1,593원	비싸지만 거의 균일
...	강원·충남·경기	1,564~1,565원	
최저권	부산·경남·대구	~1,543원	싼 편

- 발견: 지역이 가격차이의 약 15% 설명(브랜드보다 영향 큼). 기름값 쌀 때도 지역 격차 유지 → 임대료·운영비 구조 반영.

📊 Part 5. 가격 안정성 — "가격을 자주 바꾸나?"

- 방법: 변동계수(CV) = 표준편차 ÷ 평균 × 100 + 산점도/추세선 + Violin
- 실제 결과: 대부분 CV < 1% → 일주일간 가격 거의 안 바꿈 (전체 평균 0.268%)
- 가장 안정적: 알뜰(ex) 0.157% / 가장 변동 큼: 알뜰주유소 0.326%

🧩 Part 6. 종합 결론

- 꼭대기 결론 + 근거 4개를 한 장으로 묶고 → 이해관계자별 시사점:

이해관계자	시사점
소비자	셀프+알뜰 선택으로 연 수만 원 절감
정유사	알뜰 확대 대응, 브랜드 로열티 전략 재검토
정책	서울·제주 프리미엄은 규제보다 경쟁구조 개선으로
창업자	알뜰 가맹 vs 고마진 지역 입점 양극화

3. 발표자료(.pptx) 10장 구성

1. 타이틀 (숫자 임팩트) → 2. 목차 → 3. SCQA → 4. 연도별가격 → 5. 브랜드 → 6. 셀프vs일반 → 7. 지역 → 8. 지도 → 9. 전략 시사점 → 10. 결론 (피라미드)

- 타이틀 장에 320,539 데이터행 / 45,809 분석건 / 17시도×4년을 큰 숫자로 강조
- 모든 장에 섹션 번호(01~07) + Header Message(한 줄 결론) → Notion이 말한 "타이틀/Header Message/섹션 인디케이터" 형식

4. ⚠️ 그대로 베끼면 안 되는 이유 (완성본의 숫자 불일치)

발표 문장(글)과 실제 계산된 숫자가 **안 맞는** 곳이 있다. 글은 따로 쓰고 숫자는 코드가 계산했는데 둘을 안 맞춘 흔적.

항목	글/슬라이드 주장	실제 계산값	판정
브랜드 효과크기 η^2	" ≈ 0.10 , 큰 효과"	0.048, 작은 효과	❌ 불일치
셀프 효과크기 Cohen's d	" ≈ 0.2 , 작은 효과"	평균 0.53, 중간 효과	❌ 불일치
브랜드 ANOVA F	" $F > 100$ "	$F = 80.5$	❌ 불일치
연도 평균가격	1,268 / 1,553	1,284 / 1,559	⚠️ 단위 차이(미세)

👉 직접 숫자를 다시 계산해 글과 맞추면 모범답안보다 더 정확한 결과물이 된다.

5. 따라 할 "뼈대" (다른 주제에도 재사용)

SCQA로 질문 던지기

- 근거1 (연도) : [기초통계] + [차트] + [한 줄 해석]
- 근거2 (브랜드): [ANOVA] + [차트] + [한 줄 해석]
- 근거3 (셀프) : [t-검정] + [차트] + [한 줄 해석]
- 근거4 (지역) : [분산분해] + [지도] + [한 줄 해석]
- 피라미드로 결론 묶기 → 이해관계자 시사점

매 분석이 "이론 한 줄 → 코드 → 숫자 → 차트 → 해석 한 줄" 패턴의 반복.

6. 알아야 할 통계 용어 (한 줄 정리)

용어	쉽게	어디 쓰였나
평균/중앙값	보통값 / 한가운데값	연도·지역 가격
표준편차·IQR	값이 흩어진 정도	가격 격차
왜도(Skewness)	분포가 한쪽으로 쏠림	고가 주유소 영향
ANOVA + η^2	3집단↑ 차이검정 + 그 차이가 얼마나 큰지	브랜드
t-검정 + Cohen's d	2집단 차이검정 + 차이 크기	셀프 vs 일반
분산분해	차이가 "그룹 간"인지 "그룹 안"인지 쪼갬	지역
변동계수(CV)	평균 대비 들쭉날쭉함	가격 안정성

해설 작성 기준: 실행 완료된 SCQA 노트북(35셀) + 예시 보고서 pptx(10장) 직접 분석.